

Dicionário de dados: Filmes, reputação x retorno financeiro

Oct 3, 2026 · @Danielli

Como usar este dicionário

Este dicionário define cada coluna e cada termo usado no projeto de análise da base IMDB Movies, do arquivo original aos arquivos exportados para o dashboard. Os nomes de coluna aparecem exatamente como estão no notebook e nos CSVs.

A análise usa duas bases, e quase todo número do projeto vem de uma delas:

Base	Filmes	Para que serve
df (base limpa)	9.790	Tudo o que envolve nota do público
fin (subconjunto financeiro)	4.642 (47%)	Tudo o que envolve dinheiro: receita, orçamento, lucro e ROI

Valores em dinheiro estão em dólares americanos (US\$), como vieram da base original. A nota vai de 0 a 100.

Colunas da base original

A base do Kaggle tem 10.178 linhas e 12 colunas. Na limpeza, todas foram renomeadas para português e tiveram espaços invisíveis e espaços extras removidos.

Coluna original	Nome na análise	Tipo	O que significa	Cuidado ao usar
names	titulo	texto	Título do filme em inglês	Há homônimos, como <i>Titanic</i> (1953 e 1997)
date_x	data_lancamento	data	Data de estreia, no formato mês/dia/ano na origem	Em geral é a estreia na Austrália, não nos EUA

Coluna original	Nome na análise	Tipo	O que significa	Cuidado ao usar
score	nota	número	Nota média do público, de 0 a 100	211 filmes com nota 0 foram removidos. Não há número de votos
genre	genero	texto	Gêneros separados por vírgula	85 nulos, preenchidos com "Não informado"
overview	sinopse	texto	Resumo do enredo	Sinopses de preenchimento ("We don't have an overview") viraram nulo
crew	elenco	texto	Pares "ator, personagem"	Apesar do nome (equipe), só traz elenco. Sem diretor, roteirista ou produtor
orig_title	titulo_original	texto	Título no idioma original	Sem tratamento adicional
status	status	texto	Released, Post Production ou In Production	Usada no filtro e depois removida
orig_lang	idioma	categoria	Idioma original do filme	Rótulos unificados, como "Spanish, Castilian" para "Spanish"
budget_x	orcamento	número (US\$)	Orçamento de produção	Não inclui marketing. 328 valores com centavos
revenue	receita	número (US\$)	Bilheteria bruta mundial	3.398 valores com centavos e valores repetidos entre filmes

Coluna original	Nome na análise	Tipo	O que significa	Cuidado ao usar
country	país	categoria	País da data de estreia registrada	Não é o país de produção. Mede alcance de distribuição

Colunas criadas na limpeza e no enriquecimento

Essas colunas foram criadas nas seções 3.1 a 3.8 do notebook. As que vêm da Wikipedia e do Wikidata preenchem lacunas que a base original não cobria.

Coluna	Tipo	O que significa	Origem
id	inteiro	Identificador interno sequencial, de 1 a 9.790, um por filme	Criada (3.4)
ano, mes, decada	inteiro	Ano, mês e década derivados de data_lancamento	Criada (3.1)
conflito_financeiro	verdadeiro/falso	O mesmo filme aparecia em linhas duplicadas com receitas diferentes. 166 filmes	Criada (3.3)
homonimo_herdado	verdadeiro/falso	Filme mais antigo que repete a receita de um homônimo mais recente, como <i>Titanic</i> (1953). 212 filmes	Criada (3.3)
E_remake?	0 ou 1	1 quando o filme consta como remake nas listas da Wikipedia. 213 filmes	Wikipedia (3.5)
original_wiki	texto	Filme original do qual o remake foi feito, com o ano	Wikipedia (3.5)
wikidata_id	texto	Identificador universal do filme no Wikidata (ex.: Q3604746). Resolve homônimos	Wikidata (3.6)
Diretor	texto	Diretor ou diretores do filme, separados por vírgula. 7.787 filmes (80%)	Wikidata (3.6)

Coluna	Tipo	O que significa	Origem
<code>generos_lista</code>	lista	Gêneros em formato de lista. No CSV, separados por " "	Criada (3.7)
<code>genero_principal</code>	categoria	Primeiro gênero listado para o filme	Criada (3.7)
<code>qtd_generos</code>	inteiro	Quantidade de gêneros do filme	Criada (3.7)
<code>atores</code>	lista	Só os nomes dos atores, sem os personagens, na ordem de crédito	Criada (3.7)
<code>qtd_elenco</code>	inteiro	Quantidade de atores catalogados. Mede o quanto o filme foi documentado, não o tamanho real do elenco	Criada (3.7)
<code>financeiro_confivel</code>	verdadeiro/falso	Verdadeiro quando receita e orçamento passam em todos os testes de consistência	Criada (3.8)
<code>lucro</code>	número (US\$)	Receita menos orçamento. Só preenchido no subconjunto financeiro	Criada (3.8)
<code>roi</code>	número	Receita dividida pelo orçamento. Só preenchido no subconjunto financeiro	Criada (3.8)

A coluna auxiliar `titulo_normalizado` (título sem acentos, pontuação e maiúsculas) foi usada para cruzar com a Wikipedia e removida antes da exportação.

Colunas criadas na análise

Essas colunas foram criadas na seção 5 para responder às perguntas de negócio. As marcadas com "só `fin`" existem apenas para os 4.642 filmes do subconjunto financeiro e ficam vazias nos demais.

Coluna	Tipo	O que significa	Pergunta
franquia_chave	texto	Chave tirada do título que agrupa filmes da mesma série. <i>Shrek 2</i> e <i>Shrek the Third</i> viram "shrek"	P7, P8
e_franquia	verdadeiro/falso	Verdadeiro quando a chave reúne 3 ou mais filmes, em 3 ou mais anos, com pelo menos 2 títulos diferentes, sem remakes. 278 franquias, 1.245 filmes	P7, P8
diretores_lista	lista	Diretores do filme em formato de lista	P5
qtd_diretores	inteiro	Quantidade de diretores. Filmes com 1 diretor entram na P4	P4
nota_esperada	número	Média de nota dos outros filmes do mesmo gênero principal e da mesma década	P5
residuo	número	Nota real menos nota esperada. Positivo significa que o filme superou o esperado	P5
quadrante	categoria (só fin)	Sucesso completo, Dinheiro sem reputação, Reputação sem dinheiro ou Nem um nem outro	P6, P7
top_nota	verdadeiro/falso (só fin)	Verdadeiro para os 10% de maior nota do subconjunto financeiro (nota 76 ou mais)	P3
faixa_orcamento	categoria (só fin)	Quintil de orçamento, de "1 (menores)" a "5 (maiores)"	P9
experiencia_ator	inteiro (só fin)	Em quantos filmes da base o ator principal aparece. Aproximação de "nome estabelecido"	P9

Coluna	Tipo	O que significa	Pergunta
<code>faixa_experiencia</code>	categoria (só <code>fin</code>)	Faixas de experiência do ator: 1 a 2, 3 a 5, 6 a 10, 11 a 20, 21 ou mais filmes	P9
<code>log_roi</code>	número (só <code>fin</code>)	Logaritmo de base 10 do ROI. Impede que ROIs extremos (até 225) dominem os cálculos	Teste ampliado

No notebook também existem `log_orcamento`, `log_receita`, `ator_principal` e `diretor_unico`, usadas no teste ampliado. Elas não foram exportadas para o `imdb_analitico.csv`.

Termos de negócio e de método

Os termos estão em ordem alfabética. A última coluna indica onde cada um aparece no notebook e no relatório.

Termo	Definição	Onde aparece
Bilheteria bruta	Total arrecadado nos cinemas antes da parte dos exibidores e de impostos. É o que a coluna <code>receita</code> mede	Todo o Bloco 3
Correlação de Spearman	Mede, de -1 a 1, se duas variáveis sobem e descem juntas pela ordem dos valores, sem ser distorcida por valores extremos. Perto de 0 significa sem relação	P6, P9, síntese
Dado fabricado	Valor financeiro preenchido artificialmente na base original: receitas com centavos, o mesmo valor repetido em filmes diferentes ou nota 100 com dinheiro idêntico	Diagnóstico 2.5
Diretor consistente	Diretor com 5 ou mais filmes que superou a nota esperada em pelo menos 80% deles, com resíduo médio positivo. São 116	P5

Termo	Definição	Onde aparece
Diretor recorrente	Diretor com 5 ou mais filmes na base, consistente ou não. Ter muitos filmes não é o mesmo que ser consistente	Síntese
Enriquecimento	Inclusão de dados de fontes externas para preencher o que a base não tem. Aqui, remakes da Wikipedia e diretores do Wikidata	Seções 3.5 e 3.6
Escala log	Eixo ou cálculo em que cada passo multiplica o valor por 10. Permite comparar filmes de US\$ 10 mil e de US\$ 1 bilhão no mesmo gráfico	P5, P6, teste ampliado
Franquia	Série de filmes ligados pelo título: 3 ou mais filmes, em 3 ou mais anos, com pelo menos 2 títulos diferentes. Remakes não contam	P7, P8
Homônimo	Filmes diferentes com o mesmo título. Na base, alguns herdaram a bilheteria um do outro	Diagnóstico 2.6
Lift	Quantas vezes uma característica aparece mais num grupo do que no resto. Lift 2 = duas vezes mais frequente; lift 1 = mesma frequência	P3
Mediana	Valor do meio quando os dados são ordenados. Usada no lugar da média em dinheiro, porque não é puxada pelos filmes bilionários	Todo o Bloco 3
Nota esperada	Nota que um filme "deveria" ter pelo contexto: a média dos outros filmes do mesmo gênero e década	P5
Número de votos	Quantidade de pessoas que avaliaram o filme. Não existe na base e é a maior lacuna do projeto	P2
Quadrantes	Divisão do subconjunto financeiro pela receita (25% que mais faturaram, US\$ 192,4 milhões ou mais) e pela nota mediana (66)	P6, P7

Termo	Definição	Onde aparece
Quintil	Divisão dos filmes em 5 faixas com a mesma quantidade de filmes cada	P9
Remake	Nova versão de um filme anterior, segundo as listas da Wikipedia. Não inclui novas adaptações da mesma fonte, reboots nem sequências com o mesmo título	Seção 3.5, síntese
Resíduo	Nota real menos nota esperada. Mede o quanto o filme superou ou ficou abaixo do contexto dele	P5
ROI	Retorno sobre o investimento: receita dividida pelo orçamento. Como a receita é bruta e o orçamento não inclui marketing, ROI 1 não significa empate. Serve para comparar grupos	Bloco 3
Subconjunto financeiro	Os 4.642 filmes com receita e orçamento confiáveis (<i>fin</i>). Só eles entram nas análises de dinheiro	Seção 3.8
Teste de permutação	Embaralha os rótulos (diretor, gênero etc.) entre os filmes e repete o cálculo, para medir o que seria obtido por puro acaso	P4, P5, P8
Tolerância de 2 anos	Diferença máxima aceita entre o ano da base e o da fonte externa, porque a base usa a data de estreia em outro país	Seções 3.5 e 3.6
Variação explicada além do acaso	Parcela da diferença de nota (ou receita, orçamento, ROI) entre os filmes que um fator explica, menos o que o acaso explicaria. Só entram grupos com 5 filmes ou mais	P4, teste ampliado
Viés de composição	Quando a média de um grupo reflete quais filmes caíram na base, e não o grupo como um todo. Ex.: os filmes coreanos da base	P1

Termo	Definição	Onde aparece
Viés de sobrevivência	Só os clássicos de épocas antigas foram catalogados, e os medianos sumiram. Por isso décadas antigas parecem ter notas melhores	P1, P3

Fontes externas e propriedades do Wikidata

O projeto usa três fontes além da base do Kaggle. No Wikidata, cada informação tem um código de propriedade (P) ou de item (Q); a tabela indica quais já foram usados e quais são próximos passos.

Código ou fonte	O que é	Situação
IMDB Movies Dataset (Kaggle)	Base original do projeto	Usada
List of film remakes (Wikipedia)	Listas "Original Remake" de A a M e de N a Z	Usada (3.5)
Wikidata	Base estruturada da Wikimedia, consultada por SPARQL em lotes de 100 títulos	Usada (3.6)
Q11424	Item "filme"	Usado para exigir que o resultado seja um filme
P31	Instância de (tipo de obra)	Usada na consulta. Próximo passo: filtrar o que não é filme na base
P57	Diretor	Usada (coluna Diretor)
P577	Data de publicação	Usada para conferir o ano
P58	Roteirista	Próximo passo
P162	Produtor	Próximo passo
P272	Produtora (estúdio)	Próximo passo
P179	Parte da série	Próximo passo: substituir a franquia por título

Código ou fonte	O que é	Situação
P2142	Bilheteria	Próximo passo: conferir as receitas
P2130	Custo	Próximo passo: conferir os orçamentos
P2047	Duração	Próximo passo
P345	Identificador IMDb	Próximo passo: ligar a base aos arquivos do IMDb
<code>title.ratings</code> (IMDb)	Arquivo público com a nota e o número de votos (<code>numVotes</code>)	Próximo passo
<code>title.crew</code> e <code>title.basics</code> (IMDb)	Arquivos públicos com diretores, roteiristas, duração e tipo de obra	Alternativa ao Wikidata

Arquivos do repositório

Os arquivos estão no repositório [Projeto de Análise Base de Dados IMDb](#). Os CSVs ficam na pasta `arquivosCSV` e os gráficos, na pasta `imagens`.

Arquivo	Conteúdo	Formato
<code>Projeto_imdb.ipynb</code>	Notebook completo: diagnóstico, limpeza, enriquecimento, as 9 perguntas e as conclusões	Jupyter (Google Colab)
<code>imdb_movies.csv</code>	Base original do Kaggle	10.178 linhas, 12 colunas, separador vírgula
<code>imdb_limpo.csv</code>	Base limpa ao fim da seção 3, antes das colunas de análise	9.790 linhas, 29 colunas, separador vírgula, listas separadas por " "
<code>diretores_wikidata.csv</code>	Resultado bruto da consulta ao Wikidata: <code>wikidata_id</code> , <code>titulo</code> , <code>ano_wd</code> , <code>diretor</code> (uma linha por diretor)	Cache para não consultar o Wikidata de novo

Arquivo	Conteúdo	Formato
imdb_analitico.csv	Base completa com todas as colunas de limpeza e de análise, para o dashboard	9.790 linhas, 41 colunas, separador ponto e vírgula, decimal com vírgula
ranking_diretores.csv	Um diretor por linha: diretor , filmes , residuo_medio , acima_do_esperado (fração dos filmes acima do esperado), filmes_com_financeiro , roi_mediano	384 diretores com 5 ou mais filmes, mesmo formato do analítico
fig1.png a fig12.png	Os 12 gráficos do notebook, na ordem em que aparecem	PNG, 200 dpi