

Filmes: reputação x retorno financeiro

Relatório do projeto de análise de dados no método STAR (Situação, Tarefa, Ação e Resultado)

Autora: Danielli Arçari

Contexto: Treinamento de Exploração e Análise de Dados, com perguntas de negócio propostas por Regilene

Base: IMDB Movies Dataset (Kaggle), enriquecida com Wikipedia e Wikidata

Ferramentas: Python (pandas, NumPy, Matplotlib, Seaborn), SPARQL e Google Colab

Repositório: github.com/danielli-arçari/ProjetodeAnalise_BasedeDadosIMDB

10.178 → 9.790

linhas originais e filmes válidos depois da limpeza

4.642 (47%)

filmes com receita e orçamento confiáveis

7.787 (80%)

filmes com diretor identificado via Wikidata

0,14

correlação entre nota e receita: reputação e dinheiro quase não andam juntos

35,5%

da variação da nota explicada pelo diretor, além do acaso (ator principal: 21,0%)

8% x 23 a 27%

filmes com prejuízo bruto na maior faixa de orçamento x nas demais

Resumo

Um cliente que produz e distribui filmes quer decidir onde investir. Ele precisa entender o que faz um filme ser bem aceito pelo público, o que faz um filme dar retorno financeiro e, principalmente, onde essas duas coisas não andam juntas. A base fornecida não respondia a essas perguntas como veio: um terço das receitas tinha sinais de valor fabricado, filmes homônimos herdavam a bilheteria um do outro e a coluna chamada "equipe" trazia só atores. Depois de diagnosticar e tratar esses problemas, e de trazer o diretor de cada filme do Wikidata, a análise mostra que **dinheiro compra alcance e segurança, mas não reputação**, e que **a reputação está ligada a quem dirige o filme** mais do que a qualquer outra característica disponível na base.

Situação

O cliente, a base e as perguntas

O cliente trabalha com produção e distribuição de filmes. Antes de decidir em quem apostar, ele quer entender uma tensão: nota alta não significa dinheiro garantido, e dinheiro garantido não significa reputação garantida. O pedido não era de números soltos, mas de uma investigação guiada por perguntas, com evidência em dado e explicação do porquê.

A base de partida foi o **IMDB Movies Dataset**, publicado no Kaggle: 10.178 linhas e 12 colunas, com título, data de lançamento, nota do público (de 0 a 100), gêneros, sinopse, a coluna `crew`, título original, status, idioma, orçamento, receita e país.

As perguntas de negócio

Bloco	Pergunta
1. Entendendo o cenário	P1. Além do gênero, o que mais parece influenciar a nota que um filme recebe do público?
	P2. Existe alguma coisa nesse dataset que vocês esperavam encontrar e não encontraram? O que fariam se precisassem dela?
2. Aceitação do público	P3. Filmes muito bem avaliados costumam ter algo em comum entre si, além do gênero e do orçamento?
	P4. O dataset tem informação sobre quem trabalhou em cada filme. Ela é suficiente para explicar por que alguns filmes se destacam de forma consistente?
	P5. Se existisse um "padrão de sucesso" ligado a quem faz os filmes (não os atores), como descobri-lo com os dados que temos e com os que não temos?
3. Retorno financeiro x aceitação	P6. Os filmes que mais faturaram são também os mais bem avaliados? Sempre?
	P7. O que explicaria um filme (ou uma sequência de filmes) que fatura muito, mas recebe nota mediana ou baixa?
	P8. Filmes de uma mesma série se comportam de forma parecida em nota e receita, ou cada um é um caso isolado?
	P9. Quanto maior o orçamento, melhor a nota? Os dados confirmam isso? Qual é essa relação na prática, e por quê?



Tarefa

O que precisava ser entregue

O treinamento pedia três coisas: explorar a base com intenção, guiada pelas perguntas; produzir pelo menos dois ou três gráficos coerentes; e escrever uma conclusão que ligasse o dado à interpretação, respondendo não só "o gráfico mostra X", mas "e daí?". O próprio material deixava claro que algumas perguntas não viram gráfico, porque existem para fazer pensar.

Defini mais três critérios para o meu trabalho:

- **Nenhum número sem origem.** Todo valor deste relatório sai de uma célula do notebook e pode ser reproduzido.
- **Diagnóstico antes de análise.** Toda decisão de limpeza fica registrada, com o problema encontrado e a regra aplicada.
- **Separar o que a base responde do que ela não responde.** Quando a informação não existe, a pergunta é respondida com a lacuna e com o caminho para preenchê-la.



Ação

Diagnóstico, limpeza, enriquecimento e métodos

1. Os problemas encontrados na base original

Antes de qualquer gráfico, a base passou por um diagnóstico de qualidade. Os problemas abaixo mudariam as conclusões se fossem ignorados.

Problema	Evidência	Decisão
Filmes sem nota real	211 filmes com nota 0. Deles, 164 estão marcados como lançados ("Released"), então o status sozinho não bastava.	Removidos os não lançados e os de nota 0.
Dados financeiros fabricados	3.398 receitas (33,4%) com centavos, o que não existe em bilheteria real. O valor US\$ 175.269.998,80 se repete em 143 filmes diferentes. Os cinco filmes com nota 100 têm exatamente o mesmo orçamento e a mesma receita.	Criada uma regra de confiabilidade financeira (abaixo). Dinheiro só é analisado no subconjunto que passa nela.
Linhas duplicadas com receitas cruzadas	166 grupos com mesmo título e data, com sinopse, elenco e nota idênticos, mas receitas diferentes entre as linhas.	177 linhas duplicadas removidas. Os 166 filmes ficaram marcados com conflito financeiro.
Homônimos que herdaram bilheteria	<i>Titanic</i> (1953) aparece com a receita do <i>Titanic</i> (1997). <i>The Lion King</i> (1994 e 2019) aparece com as bilheterias dos dois lançamentos.	212 filmes marcados como homônimos herdados e excluídos das análises financeiras.
Coluna "crew" sem equipe	A coluna se chama equipe, mas segue o padrão "Ator, Personagem, Ator, Personagem". Não há diretor, roteirista nem produtor.	Renomeada para elenco. Diretor trazido do Wikidata.
Ausência de identificador	Não havia coluna de ID, o que impedia separar homônimos e cruzar com fontes externas.	Criados um <code>id</code> interno e o <code>wikidata_id</code> .
Texto sujo	Espaço invisível (<code>\xa0</code>) nos gêneros, espaços nas pontas de idioma e data, 89 sinopses com texto de preenchimento.	Textos padronizados, datas convertidas, sinopses vazias viraram nulo.
"País" que não é país de produção	A coluna indica de qual país é a data de estreia registrada. No subconjunto financeiro, 72% das datas são da Austrália.	Usada apenas como sinal de alcance de distribuição, com ressalva.

Ao final da limpeza, a base ficou com **9.790 filmes**, cada um com um ID único e sem buracos na sequência.

2. A regra de confiabilidade financeira

Um filme só entra nas análises de dinheiro se a receita e o orçamento passam em todos os testes: receita e orçamento sem centavos; orçamento arredondado em centenas de milhar, como orçamentos são divulgados; receita exclusiva daquele filme; valores de pelo menos US\$ 10 mil; e nenhum sinal de conflito ou de bilheteria herdada. Dois filmes com receita implausível que passaram nos testes automáticos (*Frenemies* e *When Love Is Lust*, com receita perto de US\$ 1 bilhão) foram excluídos manualmente.

Essa regra passou por uma revisão importante. A primeira versão exigia orçamento múltiplo de US\$ 1 milhão e deixava de fora 1.727 filmes legítimos, como *The Simpsons Movie* (US\$ 72,5 milhões) e *Bicycle Thieves* (US\$ 133 mil). O corte era enviesado: tirava justamente os filmes baratos e bem avaliados. Com a regra corrigida, o subconjunto financeiro passou de 3.838 para **4.642 filmes (47% da base)**.

A partir daí, o trabalho usa duas bases: **9.790 filmes** para tudo o que envolve nota, e **4.642 filmes** para tudo o que envolve dinheiro.

3. Por que foi preciso injetar dados externos

O Bloco 2 pergunta sobre quem está por trás da produção, "não os atores, mas quem constrói o filme". A base não tem essa informação. Em vez de responder só com a lacuna, decidi preenchê-la com duas fontes abertas:

Fonte	O que foi trazido e como	Resultado
Wikipedia	As páginas "List of film remakes" (A a M e N a Z) foram lidas automaticamente. Um filme é marcado como remake quando o título coincide e o ano difere em até 2 anos, porque a base registra a estreia na Austrália.	766 remakes lidos e 213 filmes marcados. Um caso ambíguo (dois <i>Cats</i> de 2019) foi corrigido pela sinopse.
Wikidata	Consulta SPARQL em lotes de 100 títulos, exigindo que o item seja um filme (P31), com diretor (P57) e ano de lançamento compatível. Em homônimos, fica o candidato de ano mais próximo.	7.787 filmes (80%) com diretor. Sete pares de filmes que apontavam para o mesmo item do Wikidata ficaram sem diretor, em vez de receber um chute.

O Wikidata foi escolhido porque é a base estruturada que alimenta as caixas de informação da Wikipedia e responde em lote: abrir 9.790 páginas uma a uma levaria horas e esbarraria em limites de acesso. Além do diretor, ele entrega um identificador universal que resolve de vez o problema dos homônimos. O resultado da consulta foi salvo em arquivo, para que o notebook rode de novo sem consultar tudo outra vez.

4. Métodos usados nas análises

Método	Para que serve
Lift	Mede quantas vezes uma característica aparece mais entre os 10% mais bem avaliados do que no resto. Lift 2 significa duas vezes mais frequente. Usado na P3.
Variação explicada além do acaso	Mede quanto da variação da nota (ou da receita, do orçamento e do ROI) cada fator explica. Para não favorecer fatores com muitos grupos, desconta o que seria obtido ao acaso, embaralhando os rótulos 30 vezes. Só entram grupos com 5 filmes ou mais. Usado na P4 e no teste ampliado.
Nota esperada e resíduo	A nota esperada de cada filme é a média dos outros filmes do mesmo gênero e da mesma década. O resíduo é a nota real menos a esperada. Assim, um diretor de terror não é punido por trabalhar num gênero de notas mais baixas. Usado na P5.
Correlação de Spearman	Mede se duas variáveis sobem e descem juntas, sem ser distorcida pelos filmes bilionários. Usada na P6, na P9 e na síntese.
Franquia pelo título	Uma chave tirada do título agrupa <i>Shrek 2</i> e <i>Shrek the Third</i> em "shrek". É franquia o grupo com 3 ou mais filmes, em 3 ou mais anos, com pelo menos 2 títulos diferentes, sem contar remakes. Resultado: 278 franquias, com 1.245 filmes.
ROI	Receita dividida pelo orçamento. Como a receita é bilheteria bruta e o orçamento não inclui marketing, ROI 1 não significa empate. O ROI é usado para comparar grupos, não para dizer quanto cada filme lucrou.

5. O que ficou de fora e limitou a análise

Dado ausente	Por que faz falta	Como resolver
Número de votos	Uma nota 100 dada por 3 pessoas aparece igual a uma nota 87 dada por milhões. É a maior lacuna da base.	Arquivo público <code>title.ratings</code> do IMDb, ligado pelo identificador IMDb do Wikidata (P345).
Roteirista, produtor e estúdio	Só o diretor foi trazido. As outras funções de quem constrói o filme seguem de fora.	Wikidata: P58, P162 e P272, usando o <code>wikidata_id</code> já criado.
Bilheteria verificada	A regra de confiabilidade reduz o ruído, mas não o elimina (ver P7).	Wikidata: bilheteria (P2142) e custo (P2130), para conferir os valores.
Série oficial	A franquia foi detectada pelo título e deixa passar casos como <i>Batman vs Superman</i> .	Wikidata: "parte da série" (P179).

Dado ausente	Por que faz falta	Como resolver
Marketing e receita líquida	O ROI bruto superestima o retorno.	Não há fonte pública sistemática. Por isso o ROI só compara grupos.
Tipo de obra	A base mistura formatos: <i>WWE WrestleMania 39</i> e um show gravado aparecem entre os filmes de maior nota.	Filtrar pela propriedade "instância de" (P31) do Wikidata.
Duração e classificação indicativa	Afetam o público potencial de cada filme.	Wikidata (P2047) e IMDb (<code>title.basics</code>).



Resultado

Respostas às perguntas, explicação de cada gráfico e recomendações

Principais achados

#	Achado	Evidência
1	Reputação e dinheiro são objetivos diferentes. Otimizar um não entrega o outro automaticamente.	Correlação nota x receita de 0,14 (P6)
2	Orçamento compra alcance e segurança, não qualidade.	Orçamento x nota: -0,04. Orçamento x receita: 0,70 (P9)
3	Reputação vem de quem dirige. O diretor explica mais da nota do que o ator principal, o gênero, a década ou o idioma.	35,5% contra 21,0% do ator (P4)
4	O padrão de sucesso por diretor é real, e não sorte.	116 diretores consistentes, 2,4 vezes o esperado ao acaso (P5)
5	A franquia transfere dinheiro, mas não qualidade. A receita se mantém e a nota cai a partir do segundo filme.	Receita de 0,91x a 1,10x do primeiro; nota de 4 a 7 pontos menor (P8)
6	O retorno por dólar é o resultado menos previsível. Nenhum fator explica mais de 6,3% dele.	Teste ampliado

P1 Além do gênero, o que mais parece influenciar a nota que um filme recebe do público?

Resposta: o idioma, a época e o quanto o filme foi visto e catalogado. Depois do enriquecimento, o fator mais forte passa a ser o diretor (P4).




Figura 1. Nota média por idioma (idiomas com 50 filmes ou mais), por década (décadas com 20 filmes ou mais) e por tamanho do elenco catalogado. Base: 9.790 filmes.

COMO LER O GRÁFICO

No painel da esquerda, cada barra é a nota média de um idioma, e a linha tracejada é a média geral. No do meio, a linha mostra a nota média de cada década. No da direita, os filmes são agrupados pela quantidade de atores registrados na base.

O QUE O GRÁFICO MOSTRA

- Idioma:** filmes em japonês têm a maior média (68,8) e em coreano a menor (59,0). O coreano tem uma armadilha de composição: 79% desses filmes têm romance ou drama entre os gêneros, e a base inclui muitos títulos adultos pouco conhecidos. Não é o cinema coreano que é ruim, é o recorte que caiu nesta base.
- Época:** as décadas de 1930 a 1950 têm média entre 74,4 e 74,7, e a de 1960, 71,0. De 1970 em diante, tudo fica entre 64,2 e 65,7. É viés de sobrevivência: só os clássicos antigos foram catalogados, e os medianos da época sumiram.
- Visibilidade:** filmes com 9 atores ou mais catalogados têm média 65,5; com 6 ou menos, 58,7. O elenco não causa a nota. Ele indica que filmes mais documentados são filmes mais vistos.

E DAÍ?

A nota depende do filme, mas também de quem o assistiu e de quanto ele foi catalogado. Antes de comparar notas, o cliente precisa saber se está comparando filmes com plateias do mesmo tamanho. Isso leva direto à P2.

P2 Existe alguma coisa nesse dataset que vocês esperavam encontrar e não encontraram? O que fariam se precisassem dela?

Resposta: sim. Faltam o número de votos, a equipe que constrói o filme, um identificador único, a série oficial e dados financeiros confiáveis. Parte disso foi preenchida com o Wikidata, e o resto tem caminho definido.

Esta pergunta não vira gráfico: ela existe para pensar. A evidência mais forte da lacuna está nas notas extremas. Dos **20 filmes com nota 90 ou mais**, só 2 têm dado financeiro confiável, e 65% têm elenco incompleto, contra 11% na

base toda. Sete deles são em coreano. As notas extremas pertencem quase todas a filmes obscuros, porque **falta o número de votos**.

A falta de equipe foi resolvida com o diretor do Wikidata (80% da base), e a falta de identificador, com o `wikidata_id`. As demais lacunas e o caminho para cada uma estão na tabela da seção "O que ficou de fora".

E DAÍ?

Sem o número de votos, o subconjunto financeiro serve como substituto: filme com bilheteria registrada é filme que teve público real. A dispersão da nota confirma isso: o desvio padrão é de 8,0 pontos nos filmes com financeiro confiável e de 11,5 nos demais. Por isso a P3 olha para os mais bem avaliados dentro desse subconjunto.

P3 Filmes muito bem avaliados pelo público costumam ter algo em comum entre si, além do gênero e do orçamento?

Resposta: sim. Têm origem em épocas antigas ou fora de Hollywood, raramente são franquia e rendem mais por dólar investido. E, olhando os nomes, têm diretores marcantes.




Figura 2. Lift das características entre os 10% mais bem avaliados do subconjunto financeiro (nota 76 ou mais). A linha preta marca lift 1, a mesma frequência do resto da base.

COMO LER O GRÁFICO

Cada barra mostra quantas vezes uma característica aparece mais no topo do que no resto. Barras azuis (lift acima de 1) aparecem mais entre os mais bem avaliados; barras cinzas (abaixo de 1), menos.

O QUE O GRÁFICO MOSTRA

- **Permanência no tempo:** filmes dos anos 1950 aparecem 8,9 vezes mais no topo; dos anos 1960, 6,1 vezes; dos anos 1970, 3,4 vezes. É o mesmo viés de sobrevivência da P1.
- **Origem fora de Hollywood:** italiano (5,8), hindi (5,7), espanhol (3,1) e coreano (3,1). São poucos filmes (8 em italiano e 5 em hindi no topo), mas o sinal faz sentido: produção estrangeira só chega a ter bilheteria registrada aqui quando já fez sucesso no país de origem, como *Cinema Paradiso* e *Três Homens em Conflito*. O coreano é inflado por títulos obscuros, como o que tem nota 98.
- **Franquia aparece menos:** lift de 0,73.
- **Retorno proporcional maior:** o ROI mediano do topo é 4,53, contra 2,38 do resto, com orçamento mediano menor (US\$ 23 milhões contra US\$ 30 milhões).

E DAÍ?

O que une os mais bem avaliados é identidade autoral e permanência, não escala de produção. A lista do topo (*O Poderoso Chefão*, *A Lista de Schindler*, *O Senhor dos Anéis*, *A Viagem de Chihiro*, *Os Sete Samurais*) aponta para quem dirigiu esses filmes. É isso que a P4 testa.

P4 O dataset tem informação sobre quem trabalhou em cada filme. Essa informação é suficiente para explicar por que alguns filmes se destacam de forma consistente, ou falta alguma coisa?

Resposta: não é suficiente. A base original só trazia atores. Com o diretor trazido do Wikidata, ele passa a ser o fator que mais explica a nota.




Figura 3. Parcela da variação da nota explicada por cada fator, já descontado o que seria obtido ao acaso. Base: 7.185 filmes com um único diretor identificado; só entram grupos com 5 filmes ou mais.

COMO LER O GRÁFICO

Cada barra mostra quanto da diferença de nota entre os filmes é explicada por um fator. O desconto do acaso evita que fatores com muitos grupos, como diretor e ator, pareçam importantes só por terem muitos grupos.

O QUE O GRÁFICO MOSTRA

O **diretor explica 35,5%** da variação da nota, contra 21,0% do ator principal. Gênero (9,4%), década (3,3%) e idioma (2,9%) ficam bem abaixo. Entram no cálculo 308 diretores e 284 atores com 5 filmes ou mais.

E DAÍ?

Quem constrói o filme pesa mais do que quem aparece nele. Para o cliente, **a escolha do diretor é uma decisão de reputação**, e não só de custo. Ainda falta: o diretor cobre 80% da base, roteirista, produtor e estúdio continuam de fora, e sem o número de votos não dá para dar mais peso às notas com mais plateia.

P5 Se existisse um "padrão de sucesso" ligado às pessoas por trás dos filmes (não os atores, mas quem os fez), como vocês descobririam isso com os dados que têm e com os que não têm?

Resposta: medindo, para cada diretor, em quantos filmes ele superou a nota esperada para o gênero e a época, e comparando com o que o acaso produziria. O padrão existe: 116 diretores são consistentes, 2,4 vezes mais do que o acaso.




Figura 4. Diretores com 5 filmes ou mais e pelo menos 3 no subconjunto financeiro. Eixo horizontal: quanto a nota supera, em média, a esperada para o gênero e a década. Eixo vertical: ROI mediano, em escala log. O tamanho da bolha é o número de filmes.

COMO LER O GRÁFICO

As linhas tracejadas dividem o gráfico em quatro quadrantes: a vertical marca a nota esperada (resíduo zero) e a horizontal, o ROI mediano de referência (2,59). O quadrante superior direito reúne quem entrega reputação acima do esperado e retorno acima da mediana.

O QUE O GRÁFICO MOSTRA

- Dos 384 diretores com 5 filmes ou mais, **116** superaram a nota esperada em pelo menos 80% dos filmes. Embaralhando as notas entre os filmes, o esperado por sorte seria cerca de 49.
- 122 de 309** diretores ficam no quadrante superior direito. Os de maior resíduo nesse grupo são Christopher Nolan (+13,4 pontos, ROI 3,67), Hayao Miyazaki (+13,0, ROI 6,88), Peter Jackson (+11,4, ROI 3,80), Edgar Wright e Francis Ford Coppola.
- Stanley Kubrick (+13,3), Denis Villeneuve (+12,9) e Wes Anderson (+11,1) entregam reputação, mas com ROI mediano abaixo da referência (2,12, 2,46 e 1,88).
- No alto do gráfico, perto do resíduo zero, ficam diretores como Ariel Schulman e Darren Lynn Bousman: retorno muito alto com nota apenas na média, o perfil do terror de baixo orçamento.

E DAÍ?

Existe um padrão de sucesso ligado a quem faz o filme, e ele é mensurável. A recomendação prática é uma **lista de diretores com histórico consistente**, separando quem traz reputação de quem traz reputação e retorno. Com os dados que não temos, o próximo passo é repetir o mesmo teste para roteiristas, produtores e estúdios, dar mais peso às notas com mais votos e olhar a trajetória de cada diretor ao longo do tempo.

P6 Os filmes que mais faturaram são também os mais bem avaliados pelo público? Sempre?

Resposta: às vezes, mas nem perto de sempre. A correlação entre nota e receita é fraca (0,14), e reputação sem dinheiro é muito mais comum do que dinheiro sem reputação.




Figura 5. Receita (escala log) x nota do público, no subconjunto financeiro. A linha horizontal separa os 25% que mais faturaram (US\$ 192,4 milhões ou mais); a vertical marca a nota mediana (66).

COMO LER O GRÁFICO

Cada ponto é um filme. As duas linhas formam quatro grupos: sucesso completo (azul), dinheiro sem reputação (laranja), reputação sem dinheiro (verde) e nem um nem outro (cinza). A escala log impede que os filmes bilionários achatem o resto.

O QUE O GRÁFICO MOSTRA

- Os três maiores sucessos de bilheteria (*Avatar*, *Vingadores: Ultimato* e *Avatar: O Caminho da Água*) são bem avaliados, com notas de 76 a 83.
- Basta descer no ranking para a relação se desfazer: entre os 10% que mais faturaram, só 24% também estão entre os 10% de maior nota, e 144 de 465 ficam abaixo da nota mediana.
- São 708 filmes de sucesso completo, 453 de dinheiro sem reputação, 1.688 de reputação sem dinheiro e 1.793 sem nenhum dos dois.

E DAÍ?

Nota e receita são dois objetivos diferentes. O cliente precisa decidir, projeto a projeto, qual dos dois está comprando, porque otimizar um não entrega o outro.

P7 O que explicaria um filme (ou uma sequência de filmes) que fatura muito, mas recebe uma nota mediana ou baixa?

Resposta: marca conhecida, orçamento alto e gênero. O ingresso é comprado antes de o público ver o filme, e a nota é dada depois.




Figura 6. Nota mediana x ROI mediano por gênero principal, no subconjunto financeiro (gêneros com 40 filmes ou mais). O tamanho da bolha é o número de filmes.

COMO LER O GRÁFICO

Cada bolha é um gênero. Quanto mais à direita, maior a nota; quanto mais acima, maior o retorno por dólar.

O QUE O GRÁFICO MOSTRA

- **Terror** tem a menor nota mediana (61) e o maior ROI mediano (3,32). **Drama** tem a maior nota (71) e ROI de 2,36. **Suspense** tem o menor retorno (1,89), e 33% desses filmes faturaram menos do que custaram.
- O grupo dinheiro sem reputação tem perfil definido: 20% são de franquia, contra 7% no grupo reputação sem dinheiro, e o orçamento mediano é de US\$ 107,2 milhões, contra US\$ 18 milhões. *Minions*, *Transformers*, *Piratas do Caribe* e *Star Wars: A Ascensão Skywalker* lideram a lista.

E DAÍ?

Faturar com nota mediana não é acidente, é modelo de negócio: marca forte mais distribuição ampla. O que vende o ingresso é a expectativa (personagem querido, lançamento em muitas salas, marketing pesado), e a nota mede se ela foi cumprida. O terror tem público fiel e custo baixo, então qualquer bilheteria média vira retorno alto.

ALERTA SOBRE A QUALIDADE DO DADO

Na mesma lista aparecem títulos pouco conhecidos com receita perto de US\$ 1 bilhão, como *Blue Thermal*, *Un alibi*, *Death Ship* e *3-Headed Shark Attack*. Eles passaram em todos os testes de consistência. O filtro reduz o ruído, mas não o elimina. Os padrões acima se sustentam porque são medianas de centenas de filmes, mas a conferência da bilheteria com o Wikidata é um próximo passo prioritário.

P8 Filmes que fazem parte de uma mesma série/continuação se comportam de forma parecida entre si em termos de nota e receita, ou cada um é um caso isolado?

Resposta: se parecem, e muito mais em receita do que em nota. A receita se mantém ao longo da série; a nota cai a partir do segundo filme e não se recupera.




Figura 7. Diferença de nota e proporção de receita em relação ao primeiro filme da franquia, pela mediana. Base: 96 franquias com 3 ou mais filmes no subconjunto financeiro.

COMO LER O GRÁFICO

À esquerda, cada barra mostra quantos pontos de nota a continuação perde (ou ganha) em relação ao primeiro filme. À direita, quanto ela fatura em relação ao primeiro: 1,00x é a mesma receita.

O QUE O GRÁFICO MOSTRA

- **Receita:** dentro de uma franquia, a receita varia tipicamente 2,0 vezes; entre filmes sorteados ao acaso, 4,0 vezes. Do segundo ao quinto filme, ela fica entre 0,91x e 1,10x a do primeiro.
- **Nota:** o desvio dentro da franquia (6,4 pontos) é menor que entre filmes sorteados (8,8), mas a nota cai 4 pontos no segundo filme, 6 no terceiro e 7 no quarto. No quinto, a queda é de 6,5 pontos, com só 20 casos.

E DAÍ?

A franquia transfere dinheiro de um filme para o próximo, mas não transfere qualidade. A continuação é a aposta financeira mais previsível da base e também onde a reputação se desgasta. O risco não aparece na bilheteria do filme atual, aparece no valor da marca para os próximos. Ressalva: o "primeiro filme" é o primeiro da franquia que tem financeiro confiável, que nem sempre é o original.

P9 É natural pensar que quanto maior o orçamento, melhor a nota. Os dados confirmam isso? Qual é essa relação, na prática, e por que ela se comporta desse jeito?

Resposta: não confirmam. Orçamento não tem relação com a nota (-0,04), mas tem relação forte com a receita (0,70). O que o dinheiro compra é segurança.




Figura 8. Nota mediana, receita mediana e proporção de filmes com receita menor que o orçamento, por faixa de orçamento (quintis). Base: subconjunto financeiro.

COMO LER O GRÁFICO

Os filmes foram divididos em cinco faixas de mesmo tamanho, do menor para o maior orçamento. Os três painéis comparam as mesmas faixas.

O QUE O GRÁFICO MOSTRA

- **Nota:** dos filmes de US\$ 5 milhões aos de US\$ 125 milhões (medianas da menor e da maior faixa), a nota mediana fica entre 65 e 67.
- **Receita:** cresce de US\$ 17,8 milhões para US\$ 398,7 milhões.
- **Risco:** na maior faixa, só 8% dos filmes faturaram menos do que custaram; nas outras, de 23% a 27%. Os filmes mais baratos têm o maior ROI mediano (3,50), mas também risco alto.

E DAÍ?

Dinheiro paga escala: efeitos visuais, astros, número de salas e marketing. Isso aumenta quantas pessoas veem o filme, não o quanto gostam dele. A nota depende de roteiro, direção e execução, que custam pouco em proporção ao orçamento total, e filmes caros ainda criam expectativas mais altas. Para o cliente: **orçamento alto é seguro de bilheteria, não de reputação**. Para reputação, o investimento certo é a escolha de quem dirige (P4 e P5).

Análises complementares

Os gráficos abaixo aprofundam a P9 e testam outros fatores que o cliente poderia considerar: elenco, data, local, idioma e gênero.




Figura 9. Orçamento, receita, nota e ROI medianos pela experiência do ator principal (quantidade de filmes dele na base). Base: subconjunto financeiro.

COMO LER O GRÁFICO

A base não traz cachê nem fama dos atores. Como medida aproximada de nome estabelecido, usei em quantos filmes da base o ator principal aparece. À esquerda, o dinheiro; à direita, nota (laranja) e ROI (azul).

O QUE O GRÁFICO MOSTRA

Com um protagonista de 21 filmes ou mais, o orçamento mediano mais que dobra em relação aos de 1 a 2 filmes (de US\$ 18 milhões para US\$ 40 milhões), e a receita também (de US\$ 44,4 milhões para US\$ 94,9 milhões). A nota fica igual (65 contra 66), e o ROI cai um pouco (de 2,90 para 2,51). A experiência do ator tem correlação de 0,23 com o orçamento e de -0,05 com o ROI.

E DAÍ?

Boa parte do dinheiro extra de um filme caro vai para nomes conhecidos, e nomes conhecidos trazem público proporcional ao que custam. **Um astro aumenta o tamanho da aposta, não a qualidade nem a eficiência dela**. Ressalvas: a experiência conta só os filmes desta base, e a correlação não mostra a direção.




Figura 10. Variação explicada além do acaso para quatro resultados: nota, orçamento, receita e ROI. Orçamento, receita e ROI em escala log. Base: subconjunto financeiro, grupos com 5 filmes ou mais.

COMO LER O GRÁFICO

É o mesmo teste da P4, repetido para quatro resultados. Quanto mais escura a célula, mais aquele fator explica aquele resultado.

O QUE O GRÁFICO MOSTRA

- **Diretor** é o fator mais forte em nota (30,1%), orçamento (24,0%) e receita (18,1%). **Ator principal** vem em seguida (16,2%, 16,7% e 11,7%).
- **Gênero** pesa na nota e no orçamento (12%), mas pouco na receita (5,1%) e quase nada no ROI (1,8%): define quanto custa fazer o filme, não quanto ele rende por dólar.
- **País de lançamento** explica 7,8% da receita, porque mede alcance de distribuição: filmes com data da Austrália faturam, na mediana, US\$ 85,2 milhões, contra US\$ 27,8 milhões dos com data dos EUA.
- **Idioma** explica no máximo 2%, porque 90% do subconjunto é em inglês. **Mês** explica menos de 1% em tudo.
- **ROI**: nenhum fator passa de 6,3% (ator 6,3%, diretor 5,9%).

E DAÍ?

Diretor, ator, gênero e local ajudam a prever quanto o filme vai custar e faturar, mas **o retorno por dólar investido é o resultado menos previsível da base**. Para o cliente, isso significa diversificar a carteira em vez de buscar uma fórmula de ROI.




Figura 11. Receita mediana (barras) e proporção de filmes com receita menor que o orçamento (linha), por mês de lançamento. Base: subconjunto financeiro.

COMO LER O GRÁFICO

As barras usam o eixo da esquerda, em milhões de dólares; a linha usa o eixo da direita, em percentual.

O QUE O GRÁFICO MOSTRA

Janeiro, dezembro e junho têm as maiores receitas medianas (US\$ 90,1 milhões, US\$ 87,4 milhões e US\$ 86,4 milhões), meses de férias escolares nos dois hemisférios. Outubro e novembro são os meses de maior risco: 27% dos filmes faturaram menos do que custaram, contra 18% a 23% no resto do ano. Novembro e dezembro também têm a maior nota mediana (67), porque é quando estreiam os filmes que disputam prêmios.

E DAÍ?

A data ajuda, mas pouco. Escolher o mês certo não salva um projeto, mas lançar um filme comercial na temporada de prêmios aumenta o risco. Ressalva: a data é, em geral, a de estreia na Austrália.




Figura 12. Correlação de Spearman de cada fator com a nota, a receita e o ROI. Vermelho indica relação positiva; azul, negativa. Base: subconjunto financeiro.

COMO LER O GRÁFICO

Cada célula mostra se o fator anda junto (valor positivo) ou contra (valor negativo) cada resultado. Valores perto de zero indicam ausência de relação.

O QUE O GRÁFICO MOSTRA

- **Orçamento** (0,70) e **franquia** (0,18) andam com a receita, mas não com a nota (-0,04 nos dois).
- **Drama** é o fator mais ligado à nota (0,26) e anda contra a receita (-0,13). **Terror** anda contra a nota (-0,18) e levemente a favor do ROI (0,07).
- **Animação** é o único gênero com sinal positivo nas três colunas (0,09, 0,14 e 0,03). **Diretor recorrente** também é positivo nas três (0,10, 0,17 e 0,07).
- **Remake** praticamente não tem relação com nenhum resultado.

E DAÍ?

O mapa resume a tensão do cliente numa imagem: o que move a receita não é o que move a nota. Os valores são baixos porque nenhum filme é só drama ou só franquia, então o mapa serve para ver a direção de cada fator, não para prever o resultado de um filme.

Em quem apostar e por quê

Objetivo do cliente	Aposta	Evidência
Retorno previsível	Continuações de franquias estabelecidas	Receita entre 0,91x e 1,10x a do primeiro filme (P8). Custo: perda de 4 a 7 pontos de nota.

Objetivo do cliente	Aposta	Evidência
Retorno alto com pouco capital	Terror de baixo orçamento	Maior ROI mediano entre os gêneros (3,32), com a menor nota (61) (P7).
Segurança de bilheteria	Orçamentos da faixa mais alta	Só 8% com receita abaixo do orçamento, contra 23% a 27% nas outras faixas (P9).
Equilíbrio entre nota, receita e retorno	Animação	Único gênero com sinal positivo nas três medidas (síntese).
Reputação e retorno juntos	Diretores com histórico consistente e ROI acima da mediana	122 diretores no quadrante superior direito da P5, como Christopher Nolan, Hayao Miyazaki e Peter Jackson.

A recomendação central é tratar cada projeto como uma escolha explícita entre bilheteria, reputação ou as duas. Para bilheteria, os instrumentos são marca, orçamento e distribuição. Para reputação, o instrumento é quem dirige. E, como nenhum fator explica bem o retorno por dólar, a carteira deve misturar perfis de risco.

Limitações

- **Só 47% da base tem dado financeiro confiável**, e mesmo esse subconjunto ainda tem receitas implausíveis que passaram nos testes (P7).
- **Sem o número de votos**, notas de filmes obscuros pesam igual às de filmes vistos por milhões.
- **Diretor para 80% da base**. Filmes sem correspondência no Wikidata, e sete pares ambíguos, ficaram sem diretor.
- **Franquia detectada pelo título**, o que deixa passar séries com títulos diferentes.
- **ROI bruto**: a receita é bilheteria bruta e o orçamento não inclui marketing.
- **País e data** se referem à estreia registrada, em geral na Austrália, e não ao local de produção.
- **Correlação não é causa**. Bons diretores podem escolher bons projetos, e grandes produções podem escolher atores conhecidos, e não o contrário.

Próximos passos

1. **Conferir a bilheteria e o custo** com as propriedades P2142 e P2130 do Wikidata, usando o `wikidata_id` já criado, para eliminar as receitas implausíveis que restaram.
2. **Trazer o número de votos** do arquivo `title.ratings` do IMDb, ligado pelo identificador IMDb do Wikidata (P345), e dar peso maior às notas com mais plateia.
3. **Repetir o teste da P5 para roteiristas, produtores e estúdios** (P58, P162 e P272).
4. **Substituir a franquia por título pela série oficial** (P179).
5. **Filtrar o que não é filme** pela propriedade "instância de" (P31).
6. **Construir o dashboard** a partir dos arquivos `imdb_analitico.csv` e `ranking_diretores.csv`, já exportados no formato do Power BI em português.

Todos os números deste relatório saem do notebook `Projeto_imdb.ipynb` e podem ser reproduzidos a partir dos arquivos do repositório github.com/danielli-arcari/ProjetodeAnalise_BasedeDadosIMDB.